

Detecção de estresse e esforço físico a partir de sinais fisiológicos

Juan Pedro

Departamento de Computação de Sorocaba
Universidade Federal de São Carlos (UFSCar)
Sorocaba, Brasil
juanp@estudante.ufscar.br

Resumo—O monitoramento de estados fisiológicos possui aplicações importantes em saúde preventiva e medicina esportiva. Este trabalho propõe uma abordagem de Aprendizado de Máquina para classificar três estados (Estresse, Esforço Aeróbico e Anaeróbico) utilizando dados de sensores vestíveis (frequência cardíaca, atividade eletrodérmica, temperatura e acelerometria). A metodologia envolveu uma engenharia de atributos para transformar sequências de valores de diferentes frequências em dados tabulares estatísticos. Foram avaliados seis algoritmos: k-NN, Naive Bayes, Regressão Logística, SVM, MLP e XGBoost. O protocolo experimental utilizou validação cruzada estratificada e otimização de hiperparâmetros por meio do Grid Search. Embora modelos lineares tenham apresentado melhores médias na validação interna, a Rede Neural (MLP) demonstrou maior estabilidade e generalização, alcançando AUC de 0,96 no conjunto de teste da competição no Kaggle. As features derivadas da temperatura da pele e da atividade eletrodérmica mostraram-se as mais importantes para a tarefa.

Keywords—Computação Afetiva; Sinais Fisiológicos; Aprendizado de Máquina; WESAD; Detecção de Estresse.

I. INTRODUÇÃO

A capacidade de monitorar e interpretar sinais fisiológicos em tempo real contribuiu em diversas áreas como a ergonomia, o monitoramento ocupacional e o esporte de alto rendimento. Dispositivos vestíveis (*wearables*) permitem a coleta de dados como a temperatura da pele (TEMP), atividade eletrodérmica (EDA) e frequência cardíaca (HR).

O desafio principal é traduzir esses dados brutos, que muitas vezes são ruidosos e de frequências de amostragem distintas, em classificações sobre o estado do indivíduo. O objetivo deste trabalho é desenvolver modelos de Aprendizado de Máquina capazes de distinguir entre situações de estresse induzido, atividade física aeróbica e esforço anaeróbico intenso.

Este artigo descreve a metodologia utilizada durante o desenvolvimento do projeto, com foco na engenharia de atributos, otimização de hiperparâmetros e análise comparativa de classificadores, que resultou na seleção de uma Rede Neural Artificial para a predição final.

II. TRABALHOS RELACIONADOS

A área de Computação Afetiva e Reconhecimento de Atividades Humanas possui diversos estudos. Healey e Picard [1] foram pioneiros ao demonstrar que o estresse mental

pode ser detectado em cenários do mundo real (como dirigir) utilizando sensores fisiológicos, demonstrando a importância da condutância da pele e da variabilidade da frequência cardíaca.

Outro estudo que foi um marco importante na área é o trabalho de Schmidt *et al.* [2], que introduziram o dataset WESAD (*Wearable Stress and Affect Detection*). Eles estabeleceram padrões para a combinação de sensores multimodais, mostrando como combinar temperatura, EDA e movimento pode superar o uso de modalidades isoladas.

Mais recentemente, Hongn *et al.* [3] publicaram um conjunto de dados muito semelhante ao utilizado neste projeto ("*Wearable Physiological Signals under Acute Stress and Exercise Conditions*"). O trabalho deles é relevante pois introduziram um protocolo experimental que combina tarefas de indução de estresse com exercícios em bicicleta ergométrica para diferenciar zonas aeróbicas e anaeróbicas. Em seus experimentos, Hongn *et al.* reportaram uma acurácia de aproximadamente 93% utilizando o algoritmo XGBoost para classificar estresse versus repouso, servindo como uma importante referência para este estudo. Por esse motivo, o XGBoost foi incluído ao conjunto de modelos testados aqui.

Abordagens de *Deep Learning* também têm ganhado força. Modelos baseados em CNNs são frequentemente aplicados a espectrogramas de sinais fisiológicos para extração automática de features. No entanto, em cenários com poucos dados rotulados (como o nosso desafio, com $N = 75$ para treino), técnicas clássicas com engenharia de atributos manual acabam muitas vezes oferecendo melhor equilíbrio entre viés e variância.

III. DADOS E PRÉ-PROCESSAMENTO

A base de dados fornecida contém amostras de múltiplos sujeitos. Os sinais brutos estão distribuídos em arquivos CSV separados por sensor, incluindo: Temperatura (TEMP), Atividade Eletrodérmica (EDA), Aceleração (ACC), Pulso de Volume Sanguíneo (BVP), Frequência Cardíaca (HR) e Intervalos Inter-batimentos (IBI).

A. Análise Exploratória

A análise inicial da distribuição das classes no conjunto de treinamento (Figura 1) mostrou um cenário balanceado,

com 28 amostras da classe *Anaerobic*, 25 de *Stress* e 22 de *Aerobic*. Esse equilíbrio é algo bom, pois não é necessário o uso de técnicas sintéticas de balanceamento que poderiam introduzir ruído.




Figura 1. Distribuição das classes no conjunto de treinamento. O balanceamento das amostras facilita o aprendizado dos modelos.

Adicionalmente, foi realizada uma análise demográfica dos participantes com base nos metadados fornecidos. A população do estudo é composta majoritariamente por adultos jovens (média de idade de 22,4 anos, com desvio padrão de 3,5), peso médio de 69,5 kg e altura média de 171,6 cm. A Figura 2 ilustra essas características. Com isso, é importante notar que os modelos treinados estarão enviesados para este perfil demográfico específico, o que é uma limitação a ser considerada para aplicações em idosos ou crianças.




Figura 2. Perfil demográfico dos sujeitos: Idade, Gênero e Nível de Atividade Física.

B. Engenharia de Atributos

Como os sensores possuem frequências de amostragem distintas (EDA a 4Hz e ACC a 32Hz, por exemplo), foi realizada uma etapa de Engenharia de Features para transformar esses diversos valores em dados que possam ser compreendidos pelos modelos:

- 1) **Magnitude do Acelerômetro:** Para capturar a intensidade do movimento independente da orientação do

dispositivo, calculou-se a magnitude vetorial ($Mag = \sqrt{x^2 + y^2 + z^2}$).

- 2) **Estatísticas:** Para cada sinal (HR, EDA, TEMP, BVP, IBI e Mag), extraiu-se: média, desvio padrão, mínimo, máximo, e os percentis 25 (Q1) e 75 (Q3).
- 3) **Variabilidade (HRV):** Calculou-se o RMSSD (*Root Mean Square of Successive Differences*) para o sinal IBI, uma métrica para medir a atividade do sistema nervoso autônomo.

C. Tratamento de Dados e Outliers

A análise da distribuição das features geradas (Figura 3) revelou uma presença significativa de *outliers*, especialmente nos dados de EDA.




Figura 3. Distribuição das features por classe antes do escalonamento. Nota-se a presença de valores extremos (*outliers*) em diversas variáveis, justificando o uso de normalização robusta.

Para resolver este problema sem descartar dados (dado o N pequeno), optou-se pelo uso do **RobustScaler**. Esta técnica centraliza os dados pela mediana e os escala de acordo com o intervalo interquartil (IQR), tornando o treinamento mais estável do que o uso do *StandardScaler* convencional. Valores ausentes foram imputados pela mediana.

IV. PROTOCOLO EXPERIMENTAL

Os experimentos foram conduzidos em Python (Scikit-Learn). A métrica de avaliação foi a Área Sob a Curva ROC (AUC), a mesma que foi utilizada no Kaggle.

Para garantir generalização, foi utilizada a Validação Cruzada k-fold ($k = 5$) estratificada. Seis algoritmos foram avaliados e otimizados via 'GridSearchCV':

- **Regressão Logística (LR):** Otimização de regularização C e solver.
- **k-NN:** Variação de k (3 a 11).
- **SVM (RBF):** Busca por C e γ .

- **Naive Bayes:** Ajuste de suavização.
- **MLP (Rede Neural):** Arquiteturas de camadas ocultas (50, 100, 50-50) e regularização α .
- **XGBoost:** Taxa de aprendizado e número de estimadores.

V. RESULTADOS E DISCUSSÃO

A Tabela I apresenta o desempenho médio (AUC) obtido na validação cruzada (CV) e o desempenho final no Placar Público do Kaggle.

Tabela I
COMPARATIVO DE DESEMPENHO (AUC ROC)

Modelo	AUC (CV Média)	AUC (Kaggle)
Regressão Logística	0.836	0.840
SVM (RBF Kernel)	0.835	0.944
Rede Neural (MLP)	0.792	0.961
Naive Bayes	0.791	-
XGBoost	0.782	-
k-NN	0.751	-

A. Análise da diferença entre a Validação Cruzada e Kaggle

Ao comparar os resultados da validação cruzada e o placar no Kaggle, tivemos insights interessantes. Na validação interna, modelos mais simples (Regressão Logística e SVM) obtiveram médias superiores. No entanto, a análise dos boxplots de validação cruzada (Figura 4) revelou que a **Rede Neural (MLP)** apresentou a menor variância entre os folds, indicando maior estabilidade.

Essa estabilidade fez com que o modelo tivesse uma capacidade de generalização superior no conjunto de teste do Kaggle, onde a MLP ficou na primeira posição com AUC de 0.961. Isso sugere que os modelos lineares, apesar da alta média interna, estavam possivelmente sobreajustados a certas características específicas do pequeno conjunto de treino ($N = 75$).




Figura 4. Distribuição da AUC na Validação Cruzada para os modelos otimizados. A MLP demonstrou maior consistência (caixa mais compacta), o que se confirmou no conjunto de teste.

B. Análise de Erros e Features

A Matriz de Confusão da MLP (Figura 5) mostrou que o modelo teve um bom desempenho na detecção da classe **STRESS** (92% de acerto). As principais confusões ocorrem entre **AEROBIC** e **ANAEROBIC**. Fisiologicamente, isso é esperado, pois as características de situações de estresse são bem distintas das dos exercícios, que possuem semelhanças entre si.




Figura 5. Matriz de Confusão Normalizada (MLP). Note a alta precisão para a classe STRESS (0).

A análise de importância das features fortaleceu essa hipótese: as variáveis mais impactantes foram as estatísticas de **Temperatura (TEMP)** e **EDA**, fundamentais para distinguir o estresse do exercício físico, seguidas pela magnitude do acelerômetro.

VI. ESTRATÉGIA FINAL

Com base nas análises realizadas, os dois melhores modelos foram escolhidos para submissão na competição. A validação cruzada local indicou um empate estatístico entre os melhores classificadores (Regressão Logística, SVM e MLP), conforme demonstrado pelo teste de Friedman ($p = 0.216 > 0.05$).

Logo foi necessário guiar a decisão por outros critérios além da AUC interna, como a estabilidade no boxplot e a generalização observada no Placar Público do Kaggle.

- **Rede Neural (MLP):** Escolhida como modelo primário devido à sua alta estabilidade (menor dispersão no boxplot da validação cruzada) e desempenho superior no conjunto de teste público (AUC 0,961), demonstrando robustez contra o *overfitting*.
- **SVM (RBF):** Selecionado como modelo secundário por apresentar a segunda melhor performance no Kaggle (AUC 0,944) e a segunda melhor performance na Validação Cruzada (AUC 0,835).

VII. CONCLUSÃO

Este artigo descreveu o pipeline completo para a classificação de estados fisiológicos realizada. A engenharia de

atributos estatísticos facilitou muito para trabalharmos com os dados, já que eles vieram na forma de séries temporais. Embora a validação cruzada tenha apontado inicialmente para modelos lineares, a análise de estabilidade revelou a Rede Neural (MLP) como o modelo mais robusto, que foi confirmado pelo desempenho superior no conjunto de teste (AUC 0.96).

Como trabalhos futuros, sugere-se a exploração de modelos sequenciais que possam aprender diretamente das séries temporais dos dados brutos, ou técnicas de seleção de features mais adequadas ao problema.

AGRADECIMENTOS

O autor agradece à Universidade Federal de São Carlos (UFSCar) pela infraestrutura e suporte acadêmico, e ao Prof. Dr. Tiago A. Almeida pela orientação, materiais didáticos e conhecimentos transmitidos durante a disciplina de Aprendizado de Máquina.

REFERÊNCIAS

- [1] J. A. Healey and R. W. Picard, “Detecting stress during real-world driving tasks using physiological sensors,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 6, no. 2, pp. 156–166, 2005.
- [2] P. Schmidt et al., “Introducing WESAD, a multimodal dataset for wearable stress and affect detection,” in *Proc. 20th ACM Int. Conf. on Multimodal Interaction*, 2018, pp. 400–408.
- [3] A. Hongn, F. Bosch, L. E. Prado, J. M. Ferrández, and M. P. Bonomini, “Wearable physiological signals under acute stress and exercise conditions,” *Scientific Data*, vol. 12, no. 1, 2025.